

Département d'informatique et d'ingénierie

Université du Québec en Outaouais

Avril 2026

INF4173 – PROJET SYNTHÈSE

Analyse des évaluations clients dans le secteur dermocosmétique : étude de l'influence de la marque, du prix, de la catégorie et du profil utilisateur à partir de deux jeux de données distincts et complémentaires

Superviseur : Pr. MOUDOUD HAJAR

Présenter par : Naima Ait Belkacem

Table des matières

Introduction	6
1. Phase de préparation et recherche	8
Introduction	8
1.1. Contexte métier et problématique (secteur cosmétique)	8
1.2. Revue de la littérature	9
1.3. Définition des objectifs et des questions d'analyse	10
1.4 Définition du périmètre et des hypothèses	11
Conclusion	11
2. Données : acquisition, compréhension	12
Introduction	12
2.1. Description des sources de données	12
2.2 Benchmark comparatif des datasets	12
2.3. Description des paramètres	13
2.3.1 Dataset Reviews	13
2.3.2 Dataset Ingredient Analysis	14
2.4. Confidentialité, anonymisation et considérations éthiques	16
2.5. Choix des outils	16
Conclusion	16
3. Prétraitement et préparation des données	17
Introduction	17
3.1. Nettoyage des données	17
3.1.1 Vérification de valeurs manquantes :	17
3.1.2 Supprimer colonnes inutiles :	18
3.1.3 Supprimer doublons :	18
3.1.4 Conversion de format :	19
3.2. Transformation et normalisation	20
3.3. Construction d'indicateurs (KPI) et variables dérivées	21
3.4. Segmentation	23

3.5. Structuration du dataset final d'analyse	23
Conclusion	24
4. Analyse exploratoire et descriptive (EDA)	25
Introduction	25
4.1. Analyse exploratoire des données : Dataset Reviews	25
4.1.1 Analyse descriptive (notes).....	25
4.1.2 Distribution visuelle des notes	26
4.1.3 Avis par marques	27
4.1.4 Évolution du volume d'avis par année.....	28
4.1.5 Corrélation taux de recommandation et la note	29
4.1.6 Analyse de sentiment NLP	31
4.2 Analyse exploratoire des données : dataset Ingredient analysis	32
4.2.1 Analyse descriptive (prix)	32
4.2.2 Relation Prix et Note	33
4.2.3 Top 10 Marques	34
4.2.4 Distribution des Prix.....	35
4.2.5 Note moyenne par catégorie de produit.....	35
Conclusion	36
5. Analyses avancées orientées décision	37
Introduction	37
5.1 La marque comme facteur de différenciation	37
5.2 Le profil cutané modère-t-il cet effet ?	39
5.3. Satisfaction et recommandation : deux comportements distincts	41
5.4 Les produits polarisants :au cœur des paradoxes.....	42
5.5 Analyse prédictive : quelles variables prédisent la recommandation ?	44
5.6 Synthèse : facteurs déterminants des évaluations.....	46
Conclusion	47
6. Visualisation et tableau de bord (Power BI).....	48
Introduction	48

6.1. Spécification des indicateurs et besoins métier	48
6.2. Conception du dashboard	48
6.3. Réalisation et validation	51
6.4. Guide d'utilisation du tableau de bord	52
Conclusion	52
7. Interprétation et discussion des résultats.....	53
Introduction	53
7.1. Résultats clés	53
7.2. Implications métiers	55
7.3. Recommandations opérationnelles.....	55
7.4. Comparaison avec la littérature	56
Conclusion	56
8. Limites, risques et défis	57
Introduction	57
8.1. Limites liées aux données.....	57
8.2. Limites méthodologiques	58
8.3. Risques et mitigations	58
Conclusion	59
9 Perspectives et améliorations futures	60
Introduction	60
9.1 Améliorations possibles des données	60
9.2 Prolongements analytiques	60
9.3 L'intelligence artificielle comme levier d'analyse : apports et perspectives ...	61
Conclusion	61
10. Calendrier d'exécution des tâches	62
Conclusion générale	63
11. Bibliographie	65

Table des figures

Figure 1: Code de vérification de valeurs manquantes	17
Figure 2: Détection de colonnes inutiles	18
Figure 3: Suppression de valeurs inutiles.....	18
Figure 4: Vérification de l'existence de doublons	19
Figure 5: Détection de variable de types dates	19
Figure 6: Conversion vers le format date	20
Figure 7: Transformation de données	21
Figure 8:Construction d'indicateurs (KPI) gamme de prix.....	22
Figure 9:Construction d'indicateurs (KPI) sentiment_label	22
Figure 10: Segmentation	23
Figure 11: Structuration du dataset final	24
Figure 12: Statistiques descriptives des notes	25
Figure 13:Distribution des fréquences dataset review	26
Figure 14: Top 10 marques par avis.....	27
Figure 15:Evolution de volume d'avis par années	28
Figure 16:Evolution de note moyenne par années	29
Figure 17: Corrélacion taux de recommandation et la note	30
Figure 18:Analyse de sentiments VADER.....	31
Figure 19:Analyse des prix	32
Figure 20:Relation Prix et Note.....	33
Figure 21:Diagramme en barres top 10 marques	34
Figure 22:Distribution de prix.....	35
Figure 23:Note moyenne par catégorie de produit.....	36
Figure 24: Top 15 marque par note	38
Figure 25:Volume d'avis vs note moyenne.....	38
Figure 26:Note moyenne par marque et type de peau	40
Figure 27:Paradoxe de recommandation.....	41
Figure 28: Produit avec satisfaction sans recommandation	43
Figure 29:Produit sans satisfaction avec recommandation	43
Figure 30:Page 1 :Vue générale.....	49
Figure 31:Page 2 :Analyse par marque.....	49
Figure 32:Page 3 :Profil client.....	50
Figure 33:Page 4 :Analyse produit	51

Table des tableaux

Tableau 1: Benchmark comparatif des datasets Reviews et Ingredient Analysis	
.....	13
Tableau 2: Description des variables :Dataset Reviews	14
Tableau 3: Description des variables :Dataset Ingredient Analysis	16

Introduction

Ce projet consiste à réaliser une analyse de données appliquée dans un contexte réel, en lien avec le secteur de la santé dermocosmétique. L'objectif principal est de mettre en œuvre une démarche complète d'analyse de données, depuis la compréhension du contexte métier et des données disponibles jusqu'à l'interprétation des résultats afin de soutenir la prise de décision.

Le choix du secteur dermocosmétique s'explique par le fait qu'il s'agit d'un domaine à l'interface entre la santé, les produits de soin et le commerce de détail, dans lequel les entreprises manipulent des données riches, variées et réalistes, notamment des avis clients, des évaluations de produits et des informations sur les ingrédients et les marques. Ces données peuvent inclure, par exemple, des données de ventes, de produits, de stocks ou de performance, similaires à celles utilisées par les entreprises du secteur de la beauté et de la parapharmacie. Toutefois, les données issues de contextes réels présentent fréquemment des imperfections liées aux processus de collecte et aux contraintes opérationnelles, ce qui rend leur exploitation analytique plus complexe.

Dans le cadre de ce projet, deux jeux de données publics issus de la plateforme Sephora ont été sélectionnés pour leur complémentarité analytique : le dataset Reviews, composé de plus d'un million d'avis clients, et le dataset Ingredient Analysis, regroupant près de neuf mille produits avec leurs caractéristiques détaillées.

L'analyse exploratoire des données (EDA) joue un rôle central dans cette démarche. Elle permet de comprendre la structure des jeux de données, d'identifier des tendances générales, de repérer des relations entre variables et de détecter des valeurs atypiques. Ces étapes constituent le fondement de toute analyse plus avancée. Plusieurs travaux montrent que l'exploration visuelle et interactive des données facilite la compréhension des phénomènes observés et constitue une étape indispensable avant toute modélisation ou interprétation. [1]

Cependant, la détection de valeurs atypiques ou d'anomalies ne constitue pas une finalité en soi. Dans un cadre organisationnel, certains écarts peuvent être liés à des pratiques récurrentes, à des ajustements informels ou à des contraintes opérationnelles qui se sont progressivement normalisées. Ainsi, une anomalie observée dans les données peut refléter non seulement une erreur technique, mais également une réalité métier sous-jacente. Des travaux en sciences des organisations soulignent que certaines déviations peuvent devenir habituelles au

sein des entreprises, ce qui rend nécessaire une analyse contextualisée des résultats.

Cette nécessité d'interprétation rejoint des approches méthodologiques qui mettent l'accent sur la compréhension du sens et de l'expérience dans les études en contexte organisationnel. Même dans un projet centré sur l'analyse de données, l'analyste est amené à dépasser une lecture strictement statistique afin d'expliquer les résultats à la lumière du contexte métier et des pratiques professionnelles.

Par ailleurs, l'utilisation de données réelles, en particulier dans un secteur lié à la santé, soulève des enjeux importants de confidentialité et d'éthique. La littérature récente insiste sur l'importance d'intégrer des mécanismes de protection des données dès la conception des projets analytiques, notamment par l'anonymisation, la minimisation des données ou, dans certains cas, l'utilisation de données synthétiques, tout en restant vigilant quant à la qualité et à la fiabilité des résultats produits. [2]

Ainsi, ce projet s'inscrit dans une approche concrète et professionnelle, proche des situations rencontrées en entreprise. Il vise à appliquer de manière rigoureuse les notions d'analyse de données vues en informatique : exploration, qualité des données, visualisation et interprétation dans un cas réel du secteur de la santé dermocosmétique, afin de montrer comment une analyse bien conduite peut contribuer à une meilleure compréhension des phénomènes observés et soutenir la prise de décision.

Ce rapport est structuré en onze sections : après une phase de préparation et de revue de littérature, il présente successivement l'acquisition des données, le prétraitement, l'analyse exploratoire, les analyses avancées, la visualisation sous Power BI, puis l'interprétation des résultats, les limites, les perspectives et le calendrier d'exécution.

1. Phase de préparation et recherche

Introduction

Toute démarche analytique rigoureuse repose sur une compréhension claire du contexte métier et des objectifs poursuivis. Cette première section pose les fondements du projet en définissant la problématique, en situant l'étude dans la littérature existante et en précisant le périmètre d'analyse. Elle constitue le socle conceptuel sur lequel s'appuient toutes les analyses réalisées dans les sections suivantes.

1.1. Contexte métier et problématique (secteur cosmétique)

Le secteur de la santé dermocosmétique se situe à l'intersection de la santé, des soins de la peau et du commerce de détail. Il regroupe des produits destinés à améliorer ou préserver l'état de la peau tout en répondant à des exigences élevées en matière de sécurité, d'efficacité et de conformité réglementaire, et s'inscrit dans une logique commerciale de grande distribution où les plateformes numériques jouent un rôle croissant. [3] Ces caractéristiques font de ce secteur un environnement complexe pour les entreprises, tant sur le plan opérationnel que décisionnel

Dans ce contexte, les entreprises du secteur manipulent des volumes importants de données issues de multiples sources, telles que les ventes, les stocks, les produits, les canaux de distribution et les comportements des consommateurs. L'essor du commerce électronique, combiné à la digitalisation des pratiques commerciales, accentue encore la diversité et l'hétérogénéité de ces données, rendant leur exploitation analytique plus exigeante [4]

Avec l'essor des plateformes de commerce en ligne comme Sephora, les avis clients sont devenus une source d'information stratégique. [5] Ils reflètent la perception des consommateurs et peuvent influencer directement la performance commerciale d'un produit. La problématique de ce projet est la suivante :

« Comment les caractéristiques produit (catégorie, marque, prix) et le profil utilisateur (type de peau) influencent-ils les évaluations et comportements clients dans le secteur dermocosmétique, à partir de deux sources de données complémentaires ? »

1.2. Revue de la littérature

Les travaux existants portant sur l'analyse de données en contexte réel mettent en évidence que les entreprises évoluant dans les secteurs du commerce de détail et de la santé exploitent des volumes croissants de données issues de sources multiples. Ces données proviennent notamment des transactions de vente, de la gestion des stocks, des produits, des canaux numériques et des interactions clients. Cette diversité des sources rend les jeux de données particulièrement riches, mais également complexes à analyser. [6]

Dans le secteur du commerce de détail, les travaux mettent également en avant l'importance de bien identifier les sources de données pertinentes en fonction des objectifs métier. L'accumulation de données ne garantit pas nécessairement une meilleure compréhension des phénomènes observés. Au contraire, une mauvaise qualité des données ou une sélection inadaptée des sources peut conduire à des analyses biaisées et à des décisions peu fiables [6]

L'analyse exploratoire des données occupe ainsi une place centrale dans les projets d'analyse appliquée. Elle permet d'examiner les distributions, de mettre en évidence des tendances générales, d'identifier des relations entre variables et de détecter des valeurs atypiques. Les approches visuelles et interactives sont particulièrement utiles pour faciliter cette exploration et soutenir la compréhension des données réelles par les analystes

Enfin, plusieurs travaux rappellent que les anomalies ou écarts observés dans les données ne doivent pas être interprétés uniquement comme des erreurs techniques. Dans les contextes organisationnels, ces écarts peuvent refléter des pratiques opérationnelles, des contraintes structurelles ou des ajustements informels propres à l'entreprise. Une interprétation purement quantitative, sans prise en compte du contexte métier, risque alors de masquer la signification réelle des résultats

Dans les secteurs liés à la santé et aux produits dermocosmétiques, ces enjeux sont renforcés par des contraintes réglementaires et éthiques spécifiques. Les données doivent être exploitées avec prudence, en tenant compte des exigences de confidentialité et de sécurité, tout en conservant une valeur analytique suffisante pour soutenir la prise de décision. Dans ce contexte, les plateformes d'avis en ligne comme Sephora constituent un terrain d'analyse particulièrement riche, où les comportements des consommateurs peuvent être étudiés à grande échelle à partir de données authentiques [7]

1.3. Définition des objectifs et des questions d'analyse

L'objectif principal de ce projet est de réaliser une analyse de données appliquée à un contexte réel du secteur de la santé dermocosmétique, en adoptant une démarche structurée et professionnelle similaire à celle d'un data analyst en entreprise. Le projet vise à mettre en œuvre l'ensemble des étapes clés de l'analyse de données, depuis la compréhension du contexte métier et des données disponibles jusqu'à l'interprétation des résultats afin de soutenir la prise de décision.

Plus précisément, ce travail a pour objectif d'explorer des données issues d'un environnement réaliste, caractérisées par leur diversité et leurs imperfections, dans le but d'en évaluer la qualité, d'en comprendre la structure et d'en extraire des informations pertinentes. Une attention particulière est portée à la phase d'analyse exploratoire des données, considérée comme essentielle pour identifier les tendances générales, les comportements récurrents, ainsi que les écarts ou anomalies pouvant avoir une signification métier.

Le projet ne vise pas le développement de systèmes automatisés d'aide à la décision, mais intègre des techniques de modélisation légère comme l'arbre de décision à des fins exploratoires et interprétatives, où l'accent est mis sur la compréhension des données et sur la capacité à expliquer les résultats à la lumière du contexte opérationnel du secteur dermocosmétique. L'aide à la prise de décision constitue ainsi une conséquence de l'analyse, et non un objectif technologique en soi.

À partir de ces objectifs, plusieurs questions d'analyse guident la démarche du projet, notamment :

- Quels facteurs (marque, catégorie, prix, profil utilisateur) sont associés aux évaluations les plus élevées ou les plus basses ?
- Existe-t-il des différences d'évaluation selon le type de peau ou le profil de l'utilisateur ?
- Quelles marques génèrent le plus d'engagement (volume d'avis) et comment cela se compare-t-il à leur positionnement prix ?
- Quelles tendances temporelles peut-on observer dans les avis clients ?
- Quels mots et expressions caractérisent les avis positifs versus négatifs ?

1.4 Définition du périmètre et des hypothèses

Ce projet utilise deux datasets publics issus de Kaggle, tirés de la plateforme Sephora. Les deux sources ne peuvent pas être jointes directement en raison de formats d'identifiants incompatibles. La stratégie adoptée consiste à analyser chaque dataset indépendamment, puis à effectuer des rapprochements analytiques par marque et par catégorie.

Les hypothèses initiales sont les suivantes :

- Les produits de marques reconnues reçoivent davantage d'avis mais pas nécessairement des notes plus élevées.
- Le prix n'est pas un prédicteur fort de la satisfaction client dans ce secteur.
- Les utilisateurs ayant un type de peau sensible tendent à être plus critiques dans leurs évaluations.

Conclusion

Cette première section a permis de poser les fondements conceptuels du projet : la problématique de recherche a été définie, les objectifs analytiques précisés, et les hypothèses initiales formulées. La revue de littérature a mis en évidence la pertinence d'une approche exploratoire et contextualisée pour l'analyse de données dans le secteur dermocosmétique. La section suivante présente les sources de données retenues pour répondre à ces questions, ainsi que les choix méthodologiques qui ont guidé leur sélection et leur évaluation

2. Données : acquisition, compréhension

Introduction

La qualité d'une analyse de données dépend en grande partie de la qualité des données utilisées. Cette section présente les deux datasets retenus pour ce projet le dataset Reviews et le dataset Ingredient Analysis en décrivant leur origine, leur structure, leur contenu et leurs limites. Une attention particulière est portée à la question de la compatibilité entre les deux sources, ainsi qu'aux considérations éthiques liées à l'utilisation de données publiques.

2.1. Description des sources de données

Plusieurs jeux de données ont été explorés sur Kaggle afin d'identifier les plus pertinents pour répondre à l'objectif du projet. Après analyse comparative de plusieurs sources disponibles sur Kaggle, deux datasets ont été retenus pour leur pertinence analytique et leur complémentarité.

- **Sephora Products and Skincare Reviews**
- **Sephora Cosmetic's Ingredient Analysis**

Le premier contient principalement des avis clients, des évaluations numériques, ainsi que des informations relatives au profil utilisateur et aux interactions (recommandation, feedback, etc.).

Le second dataset contient des informations détaillées sur les produits : marque, catégorie, taille, formulation et ingrédients.

2.2 Benchmark comparatif des datasets

Afin d'évaluer la pertinence et la complémentarité des deux sources retenues, une comparaison structurée a été réalisée selon plusieurs critères analytiques. Le tableau 1 présente une comparaison structurée selon plusieurs critères analytiques.

Dataset	Reviews	Ingredient Analysis
Nombre de lignes	1 094 411	9 168
Nombre de colonnes	19	21

Type de variables dominantes	Texte + Numérique	Numérique + Catégoriel
Présence de variable cible (rating)	Oui	Oui
Catégorie (mono / multi-classe)	Multi-classe (plusieurs catégories produits)	Multi-classe (makeup, skincare, fragrance...)
Niveau d'observation	Avis individuel	Produit
Présence d'ingrédients	Non	Oui
Présence de texte libre	Oui (review_text)	Oui (details, ingredients)
Données marketing	Non	Oui (MarketingFlags, limited_edition, online_only...)
Volume de données	Très élevé	Moyen

Tableau 1: Benchmark comparatif des datasets Reviews et Ingredient Analysis

2.3. Description des paramètres

2.3.1 Dataset Reviews

Le tableau 2 décrit les variables du dataset Reviews.

Nom de la variable	Type	Description
Unnamed: 0	int64	Index technique généré lors de l'export CSV
author_id	object	Identifiant unique de l'utilisateur
rating	int64	Note attribuée au produit
is_recommended	float64	Indique si le produit est recommandé (binaire)

helpfulness	float64	Score d'utilité de l'avis
total_feedback_count	int64	Nombre total de retours sur l'avis
total_neg_feedback_count	int64	Nombre de retours négatifs
total_pos_feedback_count	int64	Nombre de retours positifs
submission_time	object	Date de publication de l'avis
review_text	object	Texte complet de l'avis
review_title	object	Titre de l'avis
skin_tone	object	Teint de peau déclaré
eye_color	object	Couleur des yeux
skin_type	object	Type de peau
hair_color	object	Couleur des cheveux
product_id	object	Identifiant du produit (clé de jointure)
product_name	object	Nom du produit
brand_name	object	Marque du produit
price_usd	float64	Prix du produit en USD

Tableau 2: Description des variables :Dataset Reviews

2.3.2 Dataset Ingredient Analysis

Le tableau 3 décrit les variables du dataset Ingredient Analysis.

Nom de la variable	Type	Description
id	int64	Identifiant unique du produit

brand	object	Marque du produit
category	object	Catégorie du produit
name	object	Nom du produit
size	object	Taille ou format du produit
rating	float64	Note moyenne du produit
number_of_reviews	int64	Nombre total d'avis
love	int64	Nombre d'interactions "love"
price	float64	Prix actuel
value_price	float64	Prix normal / avant réduction
URL	object	Lien vers la page produit
MarketingFlags	bool	Indicateur marketing
MarketingFlags_content	object	Description des indicateurs marketing
options	object	Options disponibles (ex : teintes)
details	object	Description détaillée
how_to_use	object	Instructions d'utilisation
ingredients	object	Liste des ingrédients
online_only	int64	Disponible uniquement en ligne
exclusive	int64	Produit exclusif

limited_edition	int64	Édition limitée
limited_time_offer	int64	Offre temporaire

Tableau 3:Description des variables :Dataset Ingredient Analysis

2.4. Confidentialité, anonymisation et considérations éthiques

Les données utilisées sont publiques, anonymisées et disponibles librement sur la plateforme Kaggle. Aucune information permettant d'identifier directement un consommateur n'est présente dans les deux datasets. Les identifiants utilisateurs (author_id) sont des codes opaques sans lien tracéable à une personne réelle. Cette anonymisation garantit le respect des principes de protection des données personnelles et permet une exploitation analytique éthiquement responsable, conformément aux bonnes pratiques en matière de recherche appliquée. [2]

2.5. Choix des outils

Les outils utilisés dans ce projet sont Python (Jupyter Notebook) pour l'analyse et le prétraitement des données, et Power BI pour la visualisation interactive et la création du tableau de bord décisionnel.

Conclusion

Cette section a permis de caractériser les deux sources de données retenues, d'en évaluer la structure et la complémentarité, et d'identifier les principales contraintes analytiques — notamment l'incompatibilité des identifiants produits qui empêche une jointure directe entre les deux tables. Ces éléments ont orienté les choix méthodologiques de la phase suivante. La section 3 détaille les opérations de prétraitement réalisées pour préparer les datasets à l'analyse.

3. Prétraitement et préparation des données

Introduction

Les données brutes, aussi riches soient-elles, ne sont que rarement exploitables directement sans une phase préalable de nettoyage et de structuration. Cette section documente l'ensemble des opérations de prétraitement appliquées aux deux datasets : nettoyage, transformation, construction de variables dérivées et segmentation en justifiant chaque choix par les besoins analytiques identifiés lors de la phase de compréhension des données

3.1. Nettoyage des données

3.1.1 Vérification de valeurs manquantes :

Une analyse des valeurs manquantes a été réalisée sur les deux datasets. Les résultats montrent qu'aucune variable ne contient de valeurs nulles dans les deux datasets, ce qui témoigne d'une bonne qualité initiale des données collectées et réduit significativement les opérations de traitement nécessaires en aval.

```
dtype: object
[17]: df_reviews.isnull().sum()
      df_website.isnull().sum()

[17]: id                0
      brand             0
      category          0
      name              0
      size              0
      rating            0
      number_of_reviews 0
      love              0
      price             0
      value_price       0
      URL               0
      MarketingFlags    0
      MarketingFlags_content 0
      options           0
      details           0
      how_to_use        0
      ingredients       0
      online_only       0
      exclusive         0
      limited_edition   0
      limited_time_offer 0
      dtvpe: int64
```

Figure 1: Code de vérification de valeurs manquantes

3.1.2 Supprimer colonnes inutiles :

Lors de l'exploration du dataset Reviews, la colonne Unnamed: 0 a été identifiée comme une variable technique générée automatiquement lors de l'export CSV. Cette colonne ne contenant aucune information analytique pertinente, elle a été supprimée afin d'améliorer la clarté et la structure du dataset.

```
[21]: print("Colonnes Reviews :")
      print(df_reviews.columns)

      print("\nColonnes Website :")
      print(df_website.columns)

Colonnes Reviews :
Index(['Unnamed: 0', 'author_id', 'rating', 'is_recommended', 'helpfulness',
      'total_feedback_count', 'total_neg_feedback_count',
      'total_pos_feedback_count', 'submission_time', 'review_text',
      'review_title', 'skin_tone', 'eye_color', 'skin_type', 'hair_color',
      'product_id', 'product_name', 'brand_name', 'price_usd'],
      dtype='object')

Colonnes Website :
Index(['id', 'brand', 'category', 'name', 'size', 'rating',
      'number_of_reviews', 'love', 'price', 'value_price', 'URL',
      'MarketingFlags', 'MarketingFlags_content', 'options', 'details',
      'how_to_use', 'ingredients', 'online_only', 'exclusive',
      'limited_edition', 'limited_time_offer'],
      dtype='object')
```

Figure 2: Détection de colonnes inutiles

```
[23]: df_reviews = df_reviews.drop(columns=["Unnamed: 0"])
      df_reviews.columns

[23]: Index(['author_id', 'rating', 'is_recommended', 'helpfulness',
      'total_feedback_count', 'total_neg_feedback_count',
      'total_pos_feedback_count', 'submission_time', 'review_text',
      'review_title', 'skin_tone', 'eye_color', 'skin_type', 'hair_color',
      'product_id', 'product_name', 'brand_name', 'price_usd'],
      dtype='object')
```

Figure 3: Suppression de valeurs inutiles

3.1.3 Supprimer doublons :

Une vérification des doublons a été réalisée sur les deux datasets (reviews et website). Aucun doublon n'a été détecté dans les deux datasets, ce qui confirme l'intégrité et la cohérence des données collectées. Cette absence de redondance garantit que chaque ligne représente une observation unique et indépendante, condition essentielle pour la validité des analyses statistiques ultérieures

```
[25]: df_reviews.duplicated().sum()
      df_website.duplicated().sum()

[25]: 0
```

Figure 4: Vérification de l'existence de doublons

3.1.4 Conversion de format :

La conversion des variables temporelles a été appliquée uniquement au dataset des reviews, car le dataset des produits ne contient aucune variable de type date.

```

+ ✂ □ □ ▶ ■ ↺ ▶▶ Code ▼

[27]: df_reviews.dtypes

[27]: author_id      object
      rating        int64
      is_recommended float64
      helpfulness    float64
      total_feedback_count int64
      total_neg_feedback_count int64
      total_pos_feedback_count int64
      submission_time object
      review_text     object
      review_title    object
      skin_tone        object
      eye_color         object
      skin_type         object
      hair_color        object
      product_id        object
      product_name      object
      brand_name        object
      price_usd         float64
      dtype: object
```

Figure 5: Détection de variable de types dates

```
[29]: df_reviews["submission_time"] = pd.to_datetime(df_reviews["submission_time"])
      df_reviews.dtypes

[29]: author_id          object
      rating            int64
      is_recommended    float64
      helpfulness       float64
      total_feedback_count  int64
      total_neg_feedback_count  int64
      total_pos_feedback_count  int64
      submission_time    datetime64[ns]
      review_text        object
      review_title       object
      skin_tone          object
      eye_color          object
      skin_type          object
      hair_color         object
      product_id         object
      product_name       object
      brand_name         object
      price_usd          float64
      dtype: object
```

Figure 6: Conversion vers le format date

3.2. Transformation et normalisation

La phase de transformation vise à enrichir les jeux de données en dérivant de nouvelles représentations des variables existantes, plus adaptées aux analyses envisagées. Pour le dataset **Reviews**, une transformation temporelle a été appliquée à la variable **submission_time**, préalablement convertie au format **datetime** lors de l'étape de nettoyage. Deux nouvelles variables ont été extraites de cette date : l'année (**annee**) et le mois (**mois**) de publication de chaque avis. Cette décomposition de la variable temporelle est essentielle pour permettre des analyses longitudinales, notamment l'étude de l'évolution du volume d'avis dans le temps ou la détection d'éventuelles tendances saisonnières.

Concernant la normalisation, il a été jugé non pertinent de procéder à une mise à l'échelle des variables numériques dans le cadre de ce projet. En effet, les analyses réalisées sont majoritairement de nature descriptive et comparative. Bien qu'un arbre de décision ait été appliqué en section 5, cet algorithme ne nécessite pas de normalisation préalable des données, contrairement à des méthodes comme la régression logistique ou les réseaux de neurones. Les variables numériques ont donc été conservées dans leur unité d'origine.

```
Name: count, dtype: int64

: # Transformation : extraction de l'année et du mois
df_reviews["annee"] = df_reviews["submission_time"].dt.year
df_reviews["mois"] = df_reviews["submission_time"].dt.month

print("Colonnes après transformation :")
print(df_reviews.columns.tolist())
print("\nExemple :")
df_reviews[["submission_time", "annee", "mois"]].head(5)

Colonnes après transformation :
['author_id', 'rating', 'is_recommended', 'helpfulness', 'total_feedback_count', 'total_neg_feedback_count', 'total_pos_feedback_count', 'submission_time', 'review_text', 'review_title', 'skin_tone', 'eye_color', 'skin_type', 'hair_color', 'product_id', 'product_name', 'brand_name', 'price_usd', 'annee', 'mois']

Exemple :
:
  submission_time  annee  mois
0    2023-02-01    2023     2
1    2023-03-21    2023     3
2    2023-03-21    2023     3
3    2023-03-20    2023     3
4    2023-03-20    2023     3
```

Figure 7: Transformation de données

3.3. Construction d'indicateurs (KPI) et variables dérivées

La construction d'indicateurs clés permet de traduire les données brutes en informations directement exploitables dans un contexte d'analyse métier. Deux variables dérivées ont été construites à partir des données disponibles.

La première variable dérivée, intitulée **gamme_prix**, a été créée à partir de la variable price du dataset Ingredient Analysis. Une fonction de classification a été définie afin de répartir les produits en trois catégories tarifaires : les produits en entrée de gamme (prix inférieur ou égal à 25 \$), en milieu de gamme (prix compris entre 25 \$ et 75 \$), et en haut de gamme (prix supérieur à 75 \$)

La seconde variable dérivée, **sentiment_label**, a été construite à partir de la variable rating du dataset Reviews. Elle classe chaque avis en trois catégories : les avis **négatifs** (notes 1 ou 2), **neutres** (note 3) et **positifs** (notes 4 ou 5). Cette catégorisation constitue une première approximation de l'analyse de sentiment, permettant de regrouper les avis selon leur polarité globale sans recourir à des techniques de traitement du langage naturel. Elle servira de base à l'analyse textuelle comparative développée dans la section 4.

```
# Construction d'un KPI : gamme de prix (dataset website)
def classer_prix(prix):
    if prix <= 25:
        return "entrée de gamme"
    elif prix <= 75:
        return "milieu de gamme"
    else:
        return "haut de gamme"

df_website["gamme_prix"] = df_website["price"].apply(classer_prix)

print("Distribution des gammes de prix :")
print(df_website["gamme_prix"].value_counts())

Distribution des gammes de prix :
gamme_prix
milieu de gamme    4945
entrée de gamme    2681
haut de gamme      1542
Name: count, dtype: int64
```

Figure 8: Construction d'indicateurs (KPI) gamme de prix

```
] : # Construction d'un KPI : catégorie de note / sentiment (dataset reviews)
def classer_note(note):
    if note <= 2:
        return "négatif"
    elif note == 3:
        return "neutre"
    else:
        return "positif"

df_reviews["sentiment_label"] = df_reviews["rating"].apply(classer_note)

print("Distribution des catégories de notes :")
print(df_reviews["sentiment_label"].value_counts())

Distribution des catégories de notes :
sentiment_label
positif    898340
négatif    114255
neutre      81816
Name: count, dtype: int64
```

Figure 9: Construction d'indicateurs (KPI) sentiment_label

3.4. Segmentation

La segmentation consiste à diviser les données en sous-groupes homogènes afin de permettre des comparaisons ciblées. Dans le cadre de ce projet, plusieurs axes de segmentation ont été définis : la marque, le type de peau de l'utilisateur, la gamme de prix, et la période de publication des avis.

Une première analyse de segmentation a été réalisée sur la variable `skin_type` du dataset `Reviews`, en calculant la note moyenne attribuée par chaque groupe de profil utilisateur. Les résultats indiquent que les notes moyennes sont très proches entre les différents types de peau : les utilisateurs ayant une peau de type `combination` attribuent en moyenne la note la plus élevée (4,31/5), suivis des profils `dry` (4,29/5), `normal` (4,28/5) et `oily` (4,27/5).

La faiblesse des écarts observés moins de 0,04 point entre le profil le mieux noté et le moins bien noté suggère que le type de peau ne constitue pas un facteur discriminant majeur dans la satisfaction client au sein de ce corpus. Ce résultat sera approfondi dans les analyses croisées de la section 5.

```
# Segmentation : note moyenne par type de peau
note_par_type_peau = df_reviews.groupby("skin_type")["rating"].mean().sort_values(ascending=False)

print("Note moyenne par type de peau :")
print(note_par_type_peau)
```

Note moyenne par type de peau :

skin_type	
combination	4.309339
dry	4.291249
normal	4.282276
oily	4.270910

Name: rating, dtype: float64

Figure 10: Segmentation

3.5. Structuration du dataset final d'analyse

À l'issue du prétraitement, le dataset `Reviews` contient 1094411

lignes et 21 colonnes, enrichi de trois nouvelles variables (`annee`, `mois`, `sentiment_label`). Le dataset `Ingredient Analysis` contient 9168 lignes et 22 colonnes, enrichi de la variable `gamme_prix`. Les deux datasets sont analysés indépendamment, avec des rapprochements effectués par marque et par catégorie.


```

7]: # Structuration du dataset final
print("=== Dataset Reviews ===")
print(f"Dimensions : {df_reviews.shape}")
print(f"Colonnes : {df_reviews.columns.tolist()}")

print("\n=== Dataset Website ===")
print(f"Dimensions : {df_website.shape}")
print(f"Colonnes : {df_website.columns.tolist()}")

=== Dataset Reviews ===
Dimensions : (1094411, 21)
Colonnes : ['author_id', 'rating', 'is_recommended', 'helpfulness', 'total_feedback_count', 'total_neg_feedback_count', 'total_pos_feedback_count', 'submission_time', 'review_text', 'review_title', 'skin_tone', 'eye_color', 'skin_type', 'hair_color', 'product_id', 'product_name', 'brand_name', 'price_usd', 'annee', 'mois', 'sentiment_label']

=== Dataset Website ===
Dimensions : (9168, 22)
Colonnes : ['id', 'brand', 'category', 'name', 'size', 'rating', 'number_of_reviews', 'love', 'price', 'value_price', 'URL', 'MarketingFlags', 'MarketingFlags_content', 'options', 'details', 'how_to_use', 'ingredients', 'online_only', 'exclusive', 'limited_edition', 'limited_time_offer', 'gamme_prix']

```

Figure 11: Structuration du dataset final

Conclusion

À l'issue de cette phase de prétraitement, les deux datasets sont structurés et enrichis de nouvelles variables analytiques : annee, mois et sentiment_label pour le dataset Reviews ; gamme_prix pour le dataset Ingredient Analysis. Ces variables dérivées constituent des indicateurs clés qui alimenteront directement les analyses exploratoires et avancées des sections suivantes. La section 4 propose une exploration systématique de ces données afin d'en dégager les premières tendances et patterns significatifs

4. Analyse exploratoire et descriptive (EDA)

Introduction

L'analyse exploratoire des données constitue une étape fondamentale dans toute démarche analytique. Elle permet de comprendre la distribution des variables, d'identifier les tendances générales, de repérer des relations entre variables et de formuler des hypothèses pour les analyses avancées présentées en section 5.

Cette section présente une exploration systématique des deux datasets Reviews et Ingredient Analysis organisée autour de leurs caractéristiques propres. Les analyses réalisées couvrent la distribution des notes, l'évolution temporelle des avis, les profils des marques, la relation entre prix et satisfaction, ainsi qu'une analyse de sentiment basée sur le traitement automatique du langage naturel.

4.1. Analyse exploratoire des données : Dataset Reviews

4.1.1 Analyse descriptive (notes)

Afin d'obtenir une première vue d'ensemble de la distribution des notes, la fonction `.describe()` a été appliquée à la variable `rating`. Elle fournit les statistiques de base suivantes : le nombre total d'observations, la moyenne, l'écart-type, les valeurs minimale et maximale, ainsi que les quartiles

```
[41]: df_reviews["rating"].describe()

[41]: count      1.094411e+06
      mean       4.299158e+00
      std       1.149444e+00
      min       1.000000e+00
      25%       4.000000e+00
      50%       5.000000e+00
      75%       5.000000e+00
      max       5.000000e+00
      Name: rating, dtype: float64

[43]: df_reviews["rating"].value_counts()

[43]: rating
      5      698951
      4      199389
      3       81816
      1       61223
      2       53032
      Name: count, dtype: int64

[ ]: 
```

Figure 12: Statistiques descriptives des notes

L'analyse descriptive de la variable rating révèle une satisfaction client globalement élevée au sein du corpus étudié. Sur un total de 1 094 411 avis, la note moyenne s'établit à 4,29 sur 5, avec un écart-type de 1,15 indiquant une dispersion modérée autour de cette moyenne. La médiane égale à 5 signifie que plus de la moitié des évaluateurs attribuent la note maximale, ce qui témoigne d'une perception majoritairement positive des produits de la plateforme. La distribution par valeur confirme cette tendance : 698 951 avis portent la note de 5 étoiles, soit environ 64% du corpus, tandis que les notes faibles (1 et 2 étoiles) représentent respectivement 61 223 et 53 032 avis, soit une proportion minoritaire d'environ 10% chacune.

4.1.2 Distribution visuelle des notes

Si les statistiques descriptives fournissent des indicateurs précis, elles ne permettent pas de visualiser la forme globale de la distribution. La représentation graphique vient compléter cette lecture en confirmant visuellement ce qu'on a calculé : la distribution est fortement asymétrique vers la gauche, avec un pic dominant à 5 étoiles.




Figure 13: Distribution des fréquences dataset review

La figure 13 illustre la distribution des notes sous forme d'histogramme confirme le caractère asymétrique de la variable rating. L'histogramme met en évidence une concentration très marquée des évaluations autour des valeurs 4 et 5, avec un pic dominant à 5 étoiles. Ce profil de distribution, qualifié de distribution à queue gauche, est caractéristique des plateformes d'avis en ligne dans le secteur cosmétique, où les consommateurs satisfaits tendent à s'exprimer davantage que les consommateurs insatisfaits. Ce biais de publication constitue une limite méthodologique à considérer lors de l'interprétation des résultats.

4.1.3 Avis par marques

Cette analyse vise à identifier les marques générant le plus grand volume d'avis clients. Le volume d'avis constitue un indicateur de notoriété et de présence commerciale, distinct de la qualité perçue : les marques les plus commentées ne sont pas nécessairement les mieux évaluées, comme le confirmeront les analyses croisées de la section 5




Figure 14: Top 10 marques par avis

L'analyse du volume d'avis par marque permet d'identifier les acteurs les plus présents dans le corpus. CLINIQUE domine avec près de 50 000 avis, suivie de Tatcha

et Drunk Elephant. Ces marques se distinguent par un fort engagement consommateur, qui peut s'expliquer par leur notoriété établie, leur positionnement accessible à un large public, ou encore leur présence historique sur la plateforme Sephora. Il est important de noter que le volume d'avis ne reflète pas nécessairement la qualité des produits, mais plutôt la popularité et la base clientèle de ces marques. Cette observation orientera les analyses comparatives ultérieures, notamment l'étude des notes moyennes par marque.

4.1.4 Évolution du volume d'avis par année

L'analyse temporelle vise à examiner l'évolution du comportement des consommateurs dans le temps, en s'appuyant sur la variable année dérivée lors de la phase de prétraitement. La figure 15 présente l'évolution du volume d'avis par année, deux dimensions ont été analysées : le volume d'avis publiés par année et la note moyenne associée à chaque période.




Figure 15: Evolution de volume d'avis par années




Figure 16: Evolution de note moyenne par années

La figure 16 illustre l'évolution de la note moyenne par année, l'analyse de l'évolution de la note moyenne par année révèle une tendance à la baisse progressive sur l'ensemble de la période couverte par le corpus. Entre 2008 et 2012, la note moyenne se maintient à un niveau élevé, oscillant autour de 4,45 sur 5. À partir de 2013, une décroissance continue est observée, atteignant un point bas de 4,21 en 2020, avant une légère remontée en 2021-2022.

Cette tendance ne reflète pas nécessairement une détérioration de la qualité des produits, mais s'interprète plutôt comme un effet de démocratisation progressive de la plateforme. Les premiers utilisateurs de Sephora en ligne constituaient une clientèle de passionnés et d'acheteurs réguliers, davantage enclins à attribuer des notes élevées. Avec la croissance de la base d'utilisateurs et l'arrivée de profils plus diversifiés, les évaluations sont devenues progressivement plus nuancées et critiques. Ce phénomène, bien documenté dans la littérature sur les plateformes d'avis en ligne, illustre l'importance de contextualiser les moyennes dans leur dimension temporelle [8]

4.1.5 Corrélation taux de recommandation et la note

Cette section examine la relation entre le taux de recommandation et la note attribuée. Deux variables sont mobilisées : la variable `is_recommended`, de nature binaire (0 = ne recommande pas, 1 = recommande), et la variable `rating`, qui mesure la satisfaction sur une échelle de 1 à 5. L'objectif est d'évaluer dans quelle mesure ces deux comportements déclaratifs sont alignés




Figure 17: Corrélation taux de recommandation et la note

Les résultats confirment une forte corrélation positive entre la note attribuée et le comportement de recommandation. Les consommateurs n'ayant pas recommandé le produit attribuent en moyenne une note de 2,07 sur 5, tandis que ceux l'ayant recommandé attribuent en moyenne une note de 4,74 sur 5. L'écart de près de 2,7 points entre ces deux groupes est analytiquement significatif et témoigne d'une cohérence élevée entre les deux variables déclaratives.

Ce résultat, bien qu'attendu intuitivement, valide la fiabilité interne des données du corpus. Il confirme que la note et la recommandation ne sont pas des variables redondantes mais complémentaires : la note mesure le niveau de satisfaction sur une échelle graduée, tandis que la recommandation traduit une intention comportementale celle de partager et de promouvoir le produit auprès d'autres consommateurs. Dans un contexte de commerce en ligne, cette distinction est importante car certains consommateurs peuvent être satisfaits d'un produit sans pour autant le recommander activement, notamment pour des raisons de prix ou d'accessibilité.

4.1.6 Analyse de sentiment NLP

L'analyse de sentiment constitue l'une des analyses les plus riches de ce projet. Cette section adopte une méthode basée sur le traitement automatique du langage naturel (NLP), en utilisant l'outil VADER (Valence Aware Dictionary and sEntiment Reasoner).

VADER est un analyseur de sentiment spécialement conçu pour les textes informels et les avis en ligne. Il attribue à chaque texte un score de sentiment basé sur le contenu réel des mots, en tenant compte de la négation, de l'intensité et du contexte.

L'analyse a été appliquée sur un échantillon représentatif de 10 000 avis issus de la colonne `review_text`.




Figure 18: Analyse de sentiments VADER

Les résultats de l'analyse VADER révèlent que 89,9% des avis analysés présentent un contenu textuel positif, 7,4% un contenu négatif, et 2,6% un contenu neutre.

La note numérique reflète la satisfaction globale du consommateur — elle intègre non seulement l'expérience avec le produit, mais aussi des facteurs externes comme le prix, le packaging, la livraison ou le service client. Un consommateur peut ainsi attribuer une note de 3/5 tout en rédigeant un texte enthousiaste sur l'efficacité du produit, simplement parce qu'il juge le prix trop élevé.

Le texte de l'avis, analysé par VADER, capture quant à lui l'expérience émotionnelle directe avec le produit. La proportion de 89,9% de textes positifs suggère que les

consommatrices de Sephora expriment majoritairement une satisfaction dans leur discours, même lorsque leur note globale est modérée.

Cette distinction entre satisfaction déclarée par la note et sentiment exprimé par le texte illustre la complexité du comportement évaluatif des consommateurs dans le secteur dermocosmétique, et souligne la valeur ajoutée des techniques NLP dans l'analyse des avis clients. [9]

4.2 Analyse exploratoire des données : dataset Ingredient analysis

4.2.1 Analyse descriptive (prix)

```
[47]: df_website["price"].describe()
```

```
[47]: count      9168.000000  
      mean       50.063237  
      std       47.164989  
      min        2.000000  
      25%       24.000000  
      50%       35.000000  
      75%       59.000000  
      max      549.000000  
      Name: price, dtype: float64
```

```
[49]: df_website["rating"].describe()
```

```
[49]: count      9168.000000  
      mean       3.990020  
      std       1.007707  
      min        0.000000  
      25%       4.000000  
      50%       4.000000  
      75%       4.500000  
      max       5.000000  
      Name: rating, dtype: float64
```

Figure 19:Analyse des prix

L'analyse descriptive de la variable price révèle une moyenne de 50 \$ et une médiane de 35 \$. L'écart entre ces deux mesures de tendance centrale suggère une distribution asymétrique positive, influencée par la présence de produits haut de gamme aux prix élevés qui tirent la moyenne vers le haut. La majorité des produits se

situent néanmoins dans une gamme de prix intermédiaire, comme le confirme la valeur du troisième quartile établie à 59 \$

4.2.2 Relation Prix et Note

Parmi les facteurs susceptibles d'influencer la satisfaction client, le prix occupe une place centrale dans les représentations communes. Il est fréquemment admis qu'un produit plus cher est perçu comme de meilleure qualité et génère une satisfaction plus élevée. Cette section vise à vérifier empiriquement cette hypothèse, formulée en section 1.4, à partir des données du dataset Ingredient Analysis. Cette section vise à vérifier empiriquement cette hypothèse à partir des données du dataset Ingredient Analysis, en examinant la relation entre le prix d'un produit et sa note moyenne agrégée, puis en comparant les notes moyennes entre les trois segments tarifaires définis lors de la phase de prétraitement.




Figure 20: Relation Prix et Note

L'analyse révèle une corrélation quasi nulle entre le prix et la note, avec un coefficient de Pearson de 0,019. Le nuage de points confirme visuellement cette absence de relation, les avis sont répartis de façon homogène sur l'ensemble de la gamme de prix.

La comparaison par segment tarifaire apporte une confirmation chiffrée : entrée de gamme (3,9/5), milieu de gamme (4,05/5) et haut de gamme (4,07/5). L'écart maximal est de 0,17 point analytiquement négligeable.

Ce résultat s'explique par l'effet d'attente : les consommateurs ajustent leurs exigences en fonction du prix payé, neutralisant ainsi l'avantage potentiel des produits premium.

4.2.3 Top 10 Marques

Cette section vise à identifier les marques disposant du plus grand nombre de produits référencés dans le dataset Ingredient Analysis, et à comparer ce classement avec celui établi en section 4.1.3 à partir du volume d'avis du dataset Reviews. Ces deux listes sont-elles cohérentes ?




Figure 21: Diagramme en barres top 10 marques

Une comparaison inter-sources révèle que CLINIQUE figure en tête des deux classements à la fois par volume de produits (dataset Website) et par volume d'avis (dataset Reviews). Ceci suggère une cohérence entre la diversité de l'offre commerciale et l'engagement consommateur associé. En revanche, certaines marques présentes parmi les 10 premières par nombre de produits n'apparaissent pas dans le top 10 des avis, indiquant que la largeur de catalogue ne garantit pas nécessairement un fort engagement client.

4.2.4 Distribution des Prix

Le boxplot de la distribution des prix met en évidence une forte asymétrie de la variable price au sein du dataset Ingredient Analysis. La boîte centrale, représentant l'intervalle interquartile $Q1 = 24\$$ à $Q3 = 59\$$.

Ces valeurs extrêmes correspondent à des produits de niche ou de luxe : parfums, soins anti-âge premium ou dispositifs cosmétiques haute technologie qui sont bien minoritaires en nombre, exercent une influence notable sur la moyenne arithmétique. Cette distribution confirme la pertinence de la variable gamme_prix construits lors de la phase de prétraitement, qui permet de neutraliser l'effet de ces valeurs extrêmes dans les analyses comparatives.




Figure 22: Distribution de prix

4.2.5 Note moyenne par catégorie de produit

Le dataset Ingredient Analysis contient une variable catégorie regroupant l'ensemble des segments produits présents sur la plateforme : skincare, makeup, fragrance, entre autres. Cette analyse vise à déterminer si certaines catégories de produits obtiennent des évaluations systématiquement supérieures aux autres, révélant ainsi des différences de satisfaction selon le type de produit




Figure 23: Note moyenne par catégorie de produit

La figure 23 présente le top 15 des marques par note moyenne. L'analyse de la note moyenne par catégorie de produit permet d'identifier les segments les mieux évalués au sein du catalogue Sephora. Les résultats révèlent que la catégorie Lid Shadow Brush obtient la note parfaite de 5/5, suivie de Cologne, Aftershave et High Tech Tools autour de 4,5/5. Les catégories de soins corporels comme Body Moisturizers, Spa Tools et Facial Peels se situent également dans une fourchette élevée (4,4-4,5/5). En bas du classement, Blush et Makeup & Travel Cases affichent les notes les plus basses, autour de 4,3/5.

Il convient d'interpréter ces résultats avec nuance. Les catégories aux notes les plus élevées correspondent souvent à des produits fonctionnels et techniques pinceaux, outils dont l'évaluation repose sur des critères objectifs facilement mesurables. En revanche, les produits de maquillage comme le Blush font l'objet d'attentes plus subjectives liées à la teinte, la pigmentation et l'adéquation au teint individuel, ce qui génère naturellement une plus grande variabilité dans les évaluations

Conclusion

L'analyse exploratoire a permis de dresser un portrait global et descriptif des deux datasets. Plusieurs tendances structurantes ont été identifiées : une satisfaction client globalement élevée mais asymétrique, une absence de corrélation entre le prix et la note, une domination de certaines marques en volume d'avis sans que cela garantisse une meilleure évaluation, et une distinction significative entre sentiment textuel mesuré par VADER et satisfaction déclarée par la note. Ces observations constituent le point de départ des analyses avancées présentées en section 5, qui

visent à dépasser la description pour identifier les facteurs réellement déterminants dans les évaluations et comportements clients

5. Analyses avancées orientées décision

Introduction

Les analyses exploratoires réalisées en section 4 ont permis de décrire les données dans leur globalité et d'identifier les premières tendances. La présente section adopte une perspective analytique plus approfondie, en croisant les variables entre elles et en mobilisant des techniques avancées : analyse croisée, traitement du langage naturel et modélisation prédictive pour répondre directement à la problématique de recherche

5.1 La marque comme facteur de différenciation

L'analyse exploratoire a révélé que certaines marques dominant le corpus par leur volume d'avis. Cependant, un volume élevé d'avis ne garantit pas nécessairement une satisfaction client supérieure. Cette section vise à examiner la relation entre la notoriété des marques mesurée par le volume d'avis et la qualité perçue mesurée par la note moyenne. L'hypothèse testée est la suivante : les marques les plus populaires sont-elles aussi les mieux évaluées par les consommateurs ?

Afin d'assurer la fiabilité statistique des résultats et d'éviter que des marques avec un faible volume d'avis ne biaisent les moyennes, seules les marques disposant d'un minimum de 1 000 avis ont été retenues dans cette analyse, la figure 24 illustre la relation entre le volume d'avis et la note moyenne.




Figure 24: Top 15 marque par note




Figure 25: Volume d'avis vs note moyenne

La figure 25 présente la note moyenne par marque et type de peau.

L'analyse comparative des marques selon deux dimensions : le volume d'avis et la note moyenne révèle un paradoxe analytiquement significatif.

Les marques générant le plus grand volume d'avis ne sont pas nécessairement celles obtenant les meilleures évaluations. CLINIQUE, première par volume avec 49 029

avis, affiche une note moyenne de 4,25/5, tandis que DAMDAM, avec seulement 1 128 avis, obtient la note moyenne la plus élevée du corpus avec 4,74/5.

Ce phénomène s'explique par un biais de sélection inhérent aux plateformes d'avis en ligne. Les marques à fort volume d'audience attirent une clientèle hétérogène, composée de premiers acheteurs, de clients fidèles et de consommateurs déçus. À l'inverse, les marques à volume plus modeste tendent à concentrer une clientèle plus ciblée, souvent mieux informée et aux attentes plus alignées avec l'offre produit. Dans le secteur dermocosmétique, ce phénomène est particulièrement marqué une marque professionnelle comme Dermalogica, recommandée par des thérapeutes, bénéficie d'une clientèle qui arrive avec des attentes réalistes et obtient ainsi une note élevée malgré un volume important de 24 415 avis.

La marque Fresh constitue un cas d'équilibre notable au sein du corpus, combinant un volume significatif de 40 886 avis et une note moyenne de 4,38/5 , parmi les meilleures du top 10 par volume d'avis. Cette performance suggère une cohérence forte entre la promesse de marque et l'expérience client réelle, ce qui en fait un modèle analytique de référence pour les marques cherchant à concilier notoriété et satisfaction.

5.2 Le profil cutané modère-t-il cet effet ?

L'analyse exploratoire a révélé que le type de peau exerce une influence très limitée sur la note moyenne globale .Cette analyse croisée permet donc de conclure que si le type de peau n'explique pas les variations de satisfaction au sein d'une même marque, le choix de la marque lui-même reste le facteur le plus déterminant dans l'évaluation, indépendamment du profil cutané du consommateur. Ce résultat anticipe et renforce les conclusions du modèle prédictif présenté en section 5.5.




Figure 26: Note moyenne par marque et type de peau

La figure 26 illustre les deux paradoxes de recommandation identifiés. La heatmap confirme que le type de peau ne constitue pas un facteur différenciateur au sein d'une même marque. Pour chacune des huit marques analysées, les notes moyennes entre les profils cutanés : combinaison, dry, normal, oily restent remarquablement proches, avec des écarts inférieurs à 0,1 point dans la plupart des cas.

Cependant cette analyse révèle un résultat nouveau et complémentaire. Des écarts significatifs existent entre les marques, et ces écarts sont constants quelle que soit la peau de la cliente. Dermalogica se distingue nettement comme la marque la plus performante de façon homogène elle obtient les meilleures notes pour tous les types de peau simultanément, avec des moyennes supérieures à 4,5/5. Ce résultat est cohérent avec son positionnement professionnel et dermocosmétique spécialisé une marque recommandée par des thérapeutes et des esthéticiennes génère une clientèle informée dont les attentes sont alignées avec l'offre produit.

À l'inverse, CLINIQUE, première marque par volume d'avis affiche des notes systématiquement plus basses que Dermalogica pour tous les types de peau, confirmant le paradoxe popularité/qualité identifié en section 5.1.

Cette analyse croisée permet donc de conclure que si le type de peau n'explique pas les variations de satisfaction au sein d'une marque, le choix de la marque lui-même reste le facteur le plus déterminant dans l'évaluation, indépendamment du profil cutané du consommateur

5.3. Satisfaction et recommandation : deux comportements distincts

L'analyse de la corrélation entre note et recommandation, réalisée en section 4, a révélé une forte cohérence entre ces deux variables. Cependant, cette cohérence n'est pas absolue. La présente analyse s'intéresse aux cas atypiques : les clients dont le comportement de recommandation contredit leur note afin d'identifier des patterns analytiquement significatifs et d'approfondir la compréhension des mécanismes de satisfaction dans le secteur dermocosmétique.

Deux profils paradoxaux ont été identifiés et analysés. Le premier qualifié de paradoxe de satisfaction sans recommandation concerne les consommateurs ayant attribué une note positive (4 ou 5 étoiles) sans pour autant recommander le produit. Le second qualifié de paradoxe de recommandation sans satisfaction — concerne les consommateurs ayant attribué une note négative (1 ou 2 étoiles) tout en recommandant le produit.




Figure 27: Paradoxe de recommandation

Le premier paradoxe : clients satisfaits mais non-recommandants, Tatcha et Drunk Elephant dominent ce profil, suivies d'Estée Lauder. Ces trois marques partagent un positionnement haut de gamme avec des prix élevés. Ce résultat suggère que la

satisfaction personnelle avec un produit premium ne se traduit pas nécessairement en recommandation universelle. Une consommatrice peut apprécier l'efficacité d'une crème Tatcha à 68\$ tout en hésitant à la recommander, consciente que son prix la rend inaccessible à la majorité. Dans le secteur dermocosmétique, ce phénomène est amplifié par la spécificité des formulations : un produit excellent pour une peau sèche peut être inadapté à une peau grasse, ce qui freine la recommandation même en cas de satisfaction personnelle.

Le second paradoxe : clients insatisfaits mais recommandants concerne une proportion plus faible du corpus. The Ordinary arrive en tête de ce profil, suivie de Tatcha et Drunk Elephant. The Ordinary se distingue par son positionnement unique une marque très technique, aux formulations actives concentrées, dont les produits nécessitent une connaissance approfondie pour être utilisés correctement. Un client peut avoir mal utilisé un produit mauvaise concentration, association contre-indiquée avec d'autres actifs obtenir une réaction cutanée, attribuer une note basse, mais reconnaître la qualité intrinsèque du produit et le recommander à des consommatrices mieux informées. C'est ce qu'on peut appeler une recommandation experte dissociée de l'expérience personnelle mais fondée sur la connaissance du produit.

Ces deux paradoxes illustrent la complexité du comportement évaluatif des consommatrices dans le secteur dermocosmétique et confirment que la note et la recommandation, bien que corrélées, mesurent des dimensions distinctes de la relation client-produit.

Afin d'approfondir ces résultats, une analyse au niveau produit a été conduite dans la section suivante, permettant d'identifier les produits spécifiques au cœur de ces comportements paradoxaux et de mieux comprendre les mécanismes sous-jacents.

5.4 Les produits polarisants : au cœur des paradoxes

En prolongement de l'analyse des paradoxes de recommandation, cette section examine les produits spécifiques au cœur de ces comportements atypiques. En conservant les mêmes marques identifiées en section 5.3, l'objectif est d'identifier quels produits génèrent une satisfaction sans recommandation et lesquels génèrent une recommandation malgré l'insatisfaction afin de comprendre la nature de ces paradoxes au niveau produit.




Figure 28: Produit avec satisfaction sans recommandation



Figure 29: Produit sans satisfaction avec recommandation

L'analyse au niveau produit révèle un résultat central : le Drunk Elephant Protini Polypeptide Moisturizer et le LANEIGE Lip Sleeping Mask apparaissent simultanément dans les deux cas paradoxaux. Ce sont les produits véritablement polarisants du corpus ils génèrent à la fois une satisfaction sans recommandation et une recommandation sans satisfaction.

Pour le Drunk Elephant Protini, ce profil bipolaire s'explique par deux facteurs combinés. D'une part son prix élevé (~68\$) freine la recommandation universelle même chez les clientes satisfaites. D'autre part sa formulation aux polypeptides, très efficace sur certains types de peau, peut provoquer des réactions d'intolérance sur d'autres profils générant une insatisfaction personnelle qui n'invalide pas la qualité intrinsèque du produit aux yeux de la cliente.

Pour le LANEIGE Lip Sleeping Mask, la nature très spécifique du produit un soin lèvres nocturne intensif explique sa présence dans les deux cas. C'est un produit de niche, très apprécié par ses utilisatrices régulières, mais perçu comme trop ciblé


pour une recommandation universelle. Les clientes insatisfaites souvent liées à une préférence de texture ou de parfum reconnaissent néanmoins sa réputation de bestseller justifiée.

Le The Ordinary Niacinamide 10% + Zinc apparaît uniquement dans le cas 2 insatisfaits mais recommandants. Ce sérum actif très concentré illustre parfaitement le profil de la recommandation experte identifiée en section 5.3 : une cliente ayant subi une intolérance initiale comprend que sa réaction est liée à son profil cutané spécifique, pas à un défaut du produit, et continue à le recommander aux profils adaptés.

Ces résultats confirment que l'insatisfaction dans le secteur dermocosmétique est rarement universelle : elle est conditionnée par l'adéquation entre la formulation du produit et le profil cutané individuel de la consommatrice. Cette observation constitue une réponse directe à l'hypothèse formulée en section 1.4, selon laquelle les utilisateurs ayant un type de peau sensible tendent à être plus critiques dans leurs évaluations.

5.5 Analyse prédictive : quelles variables prédisent la recommandation ?

Afin de dépasser l'analyse descriptive et d'identifier les variables les plus déterminantes dans le comportement de recommandation, un modèle de machine learning basé sur un arbre de décision a été appliqué. Cette approche permet de quantifier l'importance relative de chaque variable : note, marque, prix et type de peau dans la prédiction du comportement de recommandation. L'arbre de décision a été privilégié pour sa capacité à produire des résultats interprétables, sans nécessiter de normalisation préalable des données.



Les résultats du modèle sont analytiquement remarquables. Avec une précision globale de 96%, l'arbre de décision prédit correctement le comportement de recommandation dans la grande majorité des cas.

L'analyse de l'importance des variables révèle un résultat central et décisif : la note attribuée explique 99,97% de la capacité prédictive du modèle. La marque, le prix et le type de peau contribuent de manière négligeable respectivement 0,03%, 0,006% et 0,000%.

Ce résultat constitue la réponse la plus directe à la problématique de cette étude. Parmi tous les facteurs analysés : caractéristiques produit et profil utilisateur c'est la satisfaction globale exprimée par la note qui détermine quasi exclusivement le comportement de recommandation.

En d'autres termes, ni le prix du produit, ni la marque, ni le type de peau des consommateurs ne permettent de prédire le comportement de recommandation. Seule la satisfaction exprimée par la note attribuée constitue un prédicteur significatif

Cette découverte est cohérente avec l'ensemble des analyses réalisées dans ce projet. Elle confirme et unifie les résultats des sections précédentes : le prix n'influence pas la note (4.2.2), le type de peau n'influence pas la note (4.1.3), et la marque influence la note mais pas directement la recommandation (5.1). Tout converge vers une conclusion unique : dans le secteur dermocosmétique, l'expérience produit prime sur toutes les autres variables.

5.6 Synthèse : facteurs déterminants des évaluations

L'ensemble des analyses réalisées dans cette section permet de répondre directement à la problématique de recherche : *"Comment les caractéristiques produit et le profil utilisateur influencent-ils les évaluations et comportements clients dans le secteur dermocosmétique ?"*

Cinq constats structurants émergent de cette analyse :

La marque est le premier facteur de différenciation :

Les marques spécialisées à clientèle ciblée comme Dermalogica obtiennent des notes systématiquement supérieures aux grandes marques généralistes comme CLINIQUE, pourtant premières par volume d'avis. La popularité ne garantit pas la qualité perçue. Ce paradoxe s'explique par l'alignement des attentes : une clientèle informée et ciblée est plus facilement satisfaite qu'une clientèle hétérogène aux attentes variables.

Le profil cutané n'est pas un facteur discriminant :

L'analyse croisée du type de peau et de la marque confirme que les écarts de satisfaction entre profils cutanés sont négligeables inférieurs à 0,1 point dans la quasi-totalité des cas analysés quelle que soit la marque. Les produits référencés sur la plateforme Sephora semblent ainsi répondre de manière relativement homogène aux besoins des différents types de peau, ce qui infirme l'hypothèse initiale formulée en section 1.4.

Satisfaction et recommandation sont deux comportements distincts :

Des consommateurs satisfaits ne recommandent pas systématiquement notamment pour des produits haut de gamme dont le prix freine la recommandation universelle. Inversement, des consommatrices insatisfaites peuvent recommander un produit dont elles reconnaissent la valeur intrinsèque malgré une expérience personnelle négative. Ce paradoxe est particulièrement marqué pour des produits techniques comme le Drunk Elephant Protini et le LANEIGE Lip Sleeping Mask.

Les produits techniques à haute promesse concentrent l'insatisfaction :

Les catégories générant les taux d'insatisfaction les plus élevés sont les sérums actifs, les appareils de soin, les autobronzants et les crèmes solaires des produits dont l'efficacité dépend fortement du profil cutané individuel et dont les promesses marketing créent des attentes élevées. Lorsque ces promesses ne sont pas tenues, la déception se traduit par une note sévère.

La note est le seul prédicteur réel de la recommandation :

Le modèle d'arbre de décision confirme que la note attribuée explique 99,97% de la capacité prédictive du comportement de recommandation. Le prix, la marque et le type de peau n'ont aucun pouvoir prédictif significatif. Ce résultat unifie l'ensemble des analyses et apporte une réponse claire à la problématique : dans le secteur dermocosmétique, c'est l'expérience produit exprimée par la note qui détermine quasi exclusivement le comportement de recommandation, indépendamment des caractéristiques du produit ou du profil de la consommatrice.

Ces cinq constats constituent la contribution analytique centrale de ce projet. Ils seront visualisés et rendus accessibles aux décideurs dans le tableau de bord Power BI présenté dans la section suivante.

Conclusion

Les analyses avancées réalisées dans cette section ont permis de dépasser la description des données pour identifier les facteurs réellement déterminants dans les évaluations et comportements clients. Cinq constats structurants ont été établis : la marque constitue le premier facteur de différenciation ; le profil cutané n'est pas discriminant ; satisfaction et recommandation sont deux comportements distincts ; les produits techniques à haute promesse concentrent l'insatisfaction ; et la note est le seul prédicteur réel de la recommandation avec 99,97% de capacité prédictive. Ces résultats cohérents et complémentaires constituent la base analytique du tableau de bord interactif présenté dans la section 6

6. Visualisation et tableau de bord (Power BI)

Introduction

La valeur d'une analyse de données ne réside pas uniquement dans la rigueur des méthodes employées, mais également dans la capacité à communiquer les résultats de manière claire, accessible et visuellement exploitable par des décideurs non nécessairement spécialisés en analyse de données. Cette section présente la conception et la réalisation d'un tableau de bord interactif sous Power BI, qui synthétise les principaux résultats des sections 4 et 5 sous forme de visualisations dynamiques et filtrables.

6.1. Spécification des indicateurs et besoins métier

Dans le cadre de ce projet, le tableau de bord a été conçu pour répondre aux besoins d'un décideur du secteur dermocosmétique souhaitant comprendre les facteurs de satisfaction client sur la plateforme Sephora. Quatre indicateurs clés ont été définis : la note moyenne globale, le volume d'avis, le taux de recommandation et la distribution des sentiments complétés par des analyses comparatives par marque, par profil client et par catégorie de produit. Ces indicateurs traduisent directement les questions analytiques posées dans la problématique de recherche et les résultats obtenus dans les sections 4 et 5. Ces indicateurs traduisent directement les questions analytiques posées dans la problématique de recherche.

6.2. Conception du dashboard

Le tableau de bord est structuré en quatre pages thématiques, chacune répondant à une dimension spécifique de la problématique.

La **page 1 - Vue générale** : offre une synthèse globale du corpus avec trois indicateurs clés : la note moyenne (4,30/5), le nombre de marques analysées (142) et le volume total d'avis (1,094 million). La distribution des notes et le classement des marques par volume d'avis permettent une première lecture rapide et synthétique de la satisfaction client sur la plateforme, sans nécessiter d'interaction avec les filtres




Figure 30:Page 1 :Vue générale

La **page 2 -Analyse par marque** : visualise le paradoxe popularité/qualité identifié en section 5.1, à travers un nuage de points croisant volume d'avis et note moyenne. Le top 20 des marques par note moyenne complète cette vue comparative. En raison du volume important de données, un filtre par marque accessible via le volet de filtres latéral permet une exploration interactive et personnalisée.




Figure 31:Page 2 :Analyse par marque

La **page 3 -Profil client** : présente la note moyenne et le taux de recommandation par type de peau, permettant d'examiner visuellement l'influence du profil cutané sur la satisfaction client. Les résultats confirment graphiquement les conclusions analytiques de la section 5.2 : les écarts entre profils cutanés sont négligeables. Un filtre par type de peau rend cette page interactive et permet une exploration ciblée par segment.



Figure 32:Page 3 :Profil client

La **page 4 :Analyse produit** : synthétise les résultats du dataset Ingredient Analysis : note moyenne par gamme de prix, top 10 produits les plus populaires et note moyenne par catégorie de produit. Cette page s'appuie exclusivement sur le dataset website_clean, les deux tables n'ayant pas pu être reliées directement en raison de l'incompatibilité des identifiants produits identifiée en section 2.




Figure 33:Page 4 :Analyse produit

6.3. Réalisation et validation

Le tableau de bord a été développé sous Power BI Desktop et connecté aux deux datasets préalablement nettoyés et exportés au format CSV depuis l'environnement Python. Trois mesures DAX ont été créées pour calculer les indicateurs personnalisés :

- $\text{Note_Moyenne_Marque} = \text{AVERAGE}(\text{reviews_clean}[\text{rating}])$
- $\text{Taux_Recommandation} = \frac{\text{CALCULATE}(\text{COUNTROWS}(\text{reviews_clean}), \text{reviews_clean}[\text{is_recommended}] = "1.0")}{\text{COUNTROWS}(\text{reviews_clean})}$
- $\text{Note_Moyenne_Produit} = \text{AVERAGEX}(\text{website_clean}, \text{IF}(\text{website_clean}[\text{rating}] = "", \text{BLANK}(), \text{VALUE}(\text{SUBSTITUTE}(\text{website_clean}[\text{rating}], ",", ""))))$

Il convient de noter que les deux tables : reviews_clean et website_clean n'ont pas été reliées directement en raison de l'incompatibilité des clés de jointure identifiées lors de la phase de prétraitement (section 2).

Cette contrainte a conduit à structurer le tableau de bord en deux blocs distincts : les pages 1 à 3 s'appuient sur le dataset Reviews, tandis que la page 4 utilise exclusivement le dataset Ingredient Analysis. Les pages 1 à 3 s'appuient sur le dataset Reviews, tandis que la page 4 utilise le dataset Ingredient Analysis.

6.4. Guide d'utilisation du tableau de bord

Le tableau de bord est conçu pour une utilisation intuitive. La navigation entre les quatre pages s'effectue via les onglets en bas de l'écran. Les filtres disponibles par marque sur la page 2 et par type de peau sur la page 3 permettent une exploration personnalisée des données. Les KPIs de la page 1 offrent une vue synthétique immédiate, tandis que les pages suivantes permettent un approfondissement progressif selon les besoins du décideur.

Le tableau de bord est également accessible en ligne via le lien suivant : [powerbi](#)

Cette version interactive permet une exploration complète des données sans nécessiter l'installation de Power BI Desktop.

Conclusion

Le tableau de bord Power BI constitue le point de convergence visuel de l'ensemble des analyses réalisées dans ce projet. Structuré en quatre pages thématiques et alimenté par deux datasets distincts, il permet à tout décideur même non spécialisé en analyse de données de comprendre rapidement les facteurs de satisfaction client dans le secteur dermocosmétique. Les indicateurs et visualisations ainsi produits servent de base à l'interprétation approfondie et aux recommandations opérationnelles présentées dans la section 7.

7. Interprétation et discussion des résultats

Introduction

Cette section constitue le cœur interprétatif du rapport. Elle vise à dépasser la simple description des données afin de donner du sens aux résultats obtenus. L'analyse menée montre que les évaluations des consommateurs ne dépendent pas d'un seul facteur, mais d'un ensemble de dimensions combinées, parmi lesquelles la marque, la perception de la valeur, les attentes individuelles et l'expérience réelle avec le produit.

Les résultats obtenus permettent de répondre directement à la problématique posée en section 1 et de confirmer ou infirmer les hypothèses initiales formulées en section 1.4.

Les résultats doivent donc être lus dans une perspective métier, en tenant compte à la fois de la logique commerciale des marques et des spécificités du secteur dermocosmétique.

7.1. Résultats clés

L'ensemble des analyses réalisées dans ce projet permet de dégager six constats structurants en réponse à la problématique de recherche.

Une satisfaction client globalement élevée mais asymétrique :

Avec une note moyenne de 4,29/5 et une médiane de 5, le corpus révèle une satisfaction majoritairement positive. Cependant, la distribution asymétrique : 64% des avis portant la note maximale de 5 étoiles suggère un biais de publication caractéristique des plateformes d'avis en ligne, où les consommateurs satisfaits s'expriment davantage que les consommateurs insatisfaits. Ce biais constitue une limite méthodologique à prendre en compte dans l'interprétation des résultats, comme discuté en section 8

Le prix n'est pas un facteur déterminant de la satisfaction :

Le prix n'est pas un facteur déterminant de la satisfaction. Avec un coefficient de corrélation de Pearson de 0,019 entre le prix et la note, et des écarts inférieurs à 0,17 point entre les trois segments tarifaires définis en section 3.3, le niveau de prix n'explique pas les variations de satisfaction. L'effet d'attente, les consommateurs ajustant leurs exigences en fonction du prix payé neutralise l'avantage potentiel des

produits premium. Ce constat infirme directement l'une des croyances les plus répandues dans le secteur dermocosmétique

La popularité ne garantit pas la qualité perçue :

La popularité ne garantit pas la qualité perçue. Les marques générant le plus grand volume d'avis : CLINIQUE, Tatcha, Drunk Elephant ne sont pas les mieux notées.. Les marques spécialisées comme DAMDAM (4,74/5) et Dermalogica (4,61/5) obtiennent des évaluations systématiquement supérieures grâce à une clientèle ciblée aux attentes alignées.

Le profil cutané n'est pas un facteur discriminant :

Le profil cutané n'est pas un facteur discriminant. Les écarts de note entre les types de peau : combinaison (4,31), dry (4,29), normal (4,28) et oily (4,27) sont analytiquement négligeables, inférieurs à 0,04 point. Ce résultat infirme l'hypothèse initiale formulée en section 1.4, selon laquelle les utilisateurs ayant une peau sensible tendent à être plus critiques dans leurs évaluations. Les produits Sephora semblent répondre de manière équivalente aux besoins des différents profils cutanés.

Les produits techniques concentrent l'insatisfaction :

Les produits techniques concentrent l'insatisfaction. Les catégories générant les taux d'insatisfaction les plus élevés sont les sérums actifs, les appareils de soin, les autobronzants et les crèmes solaires. Ces produits à haute promesse marketing exposent les marques à un risque d'insatisfaction plus élevé lorsque les attentes créées ne correspondent pas à l'expérience réelle. Ce phénomène est particulièrement marqué pour les produits dont l'efficacité dépend fortement du profil cutané individuel, comme l'illustrent les cas du Drunk Elephant Protini et du LANEIGE Lip Sleeping Mask analysés en section 5.4.

La note est le seul prédicteur réel de la recommandation :

Le modèle d'arbre de décision confirme que la note explique 99,97% de la capacité prédictive du comportement de recommandation. Le prix, la marque et le type de peau n'ont aucun pouvoir prédictif significatif.

7.2. Implications métiers

Ces résultats comportent plusieurs implications directement actionnables pour les acteurs du secteur dermocosmétique.

Pour les marques : la cohérence entre la promesse marketing et l'expérience réelle du produit constitue le facteur le plus déterminant de la satisfaction client. [10] Une marque qui cible une clientèle informée et aligne son offre sur ses attentes comme Dermalogica, avec une note moyenne de 4,61/5 pour tous les types de peau obtient de meilleures évaluations qu'une marque qui mise uniquement sur la notoriété ou le volume. La stratégie de niche génère une satisfaction plus homogène que la stratégie de masse.

Pour les distributeurs : Le prix ne constitue pas un argument de satisfaction suffisant. Les consommateurs évaluent les produits selon leurs attentes relatives au prix payé : un produit à 15\$ bien formulé obtient la même note qu'un produit à 200\$ dont les promesses ne sont pas tenues. La qualité intrinsèque de la formulation prime sur le positionnement tarifaire.

Pour les professionnels de la beauté : Les produits techniques à actifs concentrés (sérums, acides, rétinol) génèrent plus d'insatisfaction non pas parce qu'ils sont inefficaces, mais parce qu'ils nécessitent une utilisation adaptée au profil cutané individuel. Une recommandation professionnelle personnalisée réduirait significativement le taux d'insatisfaction dans ces catégories.

7.3. Recommandations opérationnelles

Sur la base des résultats obtenus, trois recommandations concrètes peuvent être formulées.

Recommandation 1 : Personnaliser les recommandations produit selon le profil cutané. Bien que le type de peau n'influence pas significativement la note globale comme démontré en section 5.2, les produits polarisants comme le Drunk Elephant Protini et le LANEIGE Lip Sleeping Mask montrent que l'adéquation formulation-profil est déterminante dans les cas extrêmes. Une recommandation personnalisée en point de vente ou via un quiz en ligne réduirait les déceptions liées à une inadéquation produit-profil. Une recommandation personnalisée en point de vente ou via un quiz en ligne réduirait les déceptions liées à une inadéquation produit-profil.

Recommandation 2 : Mieux gérer les attentes sur les produits techniques. Les marques proposant des sérums actifs ou des appareils de soin devraient accompagner leurs produits d'une communication plus pédagogique : délais d'action réalistes, protocoles d'utilisation, profils cutanés adaptés. Cela réduirait l'écart entre les attentes et l'expérience réelle.

Recommandation 3 : Valoriser les marques à fort ratio qualité/engagement. Fresh constitue le meilleur exemple d'équilibre entre volume d'avis (40 886) et note élevée (4,38/5). Ce profil large audience combinée à une satisfaction homogène devrait être un modèle pour les marques cherchant à maximiser à la fois leur visibilité et leur réputation.

7.4. Comparaison avec la littérature

Les résultats obtenus sont cohérents avec les travaux existants sur les plateformes d'avis en ligne. La littérature en comportement du consommateur documente largement le biais de publication : les consommateurs satisfaits s'expriment davantage et l'effet d'attente : les attentes augmentent avec le prix, neutralisant l'avantage des produits premium. La découverte que la note prédit la recommandation à 99,97% est cohérente avec les travaux de Filieri et McLeay (2014), qui ont démontré que la satisfaction perçue constitue le principal déterminant de l'intention de recommandation dans les contextes d'achat en ligne. Ces auteurs montrent que la qualité de l'information et la crédibilité perçue du produit reflétées par la note sont les variables les plus influentes dans le comportement de partage d'expérience des consommateurs [7]

Conclusion

L'interprétation des résultats confirme que la satisfaction client dans le secteur dermocosmétique est un phénomène multidimensionnel qui ne peut être réduit à un seul facteur. Si la note constitue le prédicteur ultime du comportement de recommandation, elle est elle-même influencée par la cohérence entre la promesse de marque et l'expérience produit, une cohérence que les marques spécialisées maîtrisent mieux que les marques généralistes. Ces six constats structurants constituent la contribution analytique centrale de ce projet et ouvrent la voie aux limites, perspectives et recommandations présentées dans les sections 8 et 9

8. Limites, risques et défis

Introduction

Toute étude analytique comporte des limites qui en conditionnent la portée et l'interprétation. Cette section identifie et discute les principales limites de ce projet : limites liées aux données, limites méthodologiques et risques associés dans un souci de transparence scientifique et de rigueur analytique. La reconnaissance explicite de ces limites ne remet pas en cause la validité des résultats obtenus, mais en précise le périmètre d'application.

8.1. Limites liées aux données

Plusieurs limites inhérentes aux données utilisées conditionnent la portée des résultats obtenus.

- Premièrement, les deux datasets proviennent d'une source unique la plateforme Sephora ce qui limite la généralisation des résultats à l'ensemble du secteur dermocosmétique. Les comportements des consommatrices sur d'autres plateformes comme Ulta Beauty, Amazon, pharmacies pourraient différer significativement en termes de profil clientèle, de gamme de prix et de culture d'évaluation.
- Deuxièmement, les datasets sont statiques et datés. Le dataset Reviews couvre principalement la période 2008-2023, sans mise à jour en temps réel. Les tendances récentes notamment l'essor de la K-beauty, du skincare minimaliste ou des produits clean beauty ne sont peut-être pas pleinement capturées dans ce corpus. Cette limite est inhérente à l'utilisation de données publiques issues de Kaggle, qui ne bénéficient pas d'une synchronisation continue avec les plateformes sources
- Troisièmement, les deux datasets ne sont pas joignables directement en raison de l'incompatibilité des identifiants produits, comme mentionné en section 2. Cette contrainte a limité les analyses croisées entre les caractéristiques produit détaillées du dataset Ingredient Analysis et les avis individuels du dataset Reviews. Des rapprochements analytiques par marque et par catégorie ont néanmoins été réalisés afin de pallier partiellement cette limite.

- Quatrièmement, les données ne contiennent pas d'informations démographiques : âge, localisation géographique, historique d'achat ou budget qui auraient permis des segmentations plus fines et des analyses de profil consommateur plus approfondies. Cette absence limite notamment la capacité à différencier les comportements selon les marchés géographiques ou les tranches d'âge, deux dimensions pourtant importantes dans le secteur dermocosmétique

Par ailleurs, un biais de publication inhérent aux plateformes d'avis en ligne doit être formellement reconnu : les consommateurs satisfaits tendent à s'exprimer davantage que les consommateurs insatisfaits, ce qui contribue à la distribution asymétrique des notes observée dans ce corpus

8.2. Limites méthodologiques

Sur le plan méthodologique, deux limites principales doivent être signalées.

L'analyse de sentiment réalisée avec VADER constitue une première approximation du traitement automatique du langage naturel. Bien que VADER soit reconnu pour son efficacité sur les avis en ligne en anglais, il présente plusieurs limites : il ne capture pas toutes les nuances linguistiques, peut mal interpréter certains termes polysémiques comme le terme *dry*, dont le sens varie selon qu'il décrit un type de peau ou une texture de produit. Des modèles plus avancés comme BERT ou RoBERTa permettraient une analyse contextuelle plus fine, comme évoqué en section 9.

Le modèle d'arbre de décision, bien qu'affichant une précision globale de 96%, présente un résultat dominé à 99,97% par la variable note. Ce résultat, bien que cohérent et interprétable dans le contexte de cette étude, suggère une forte colinéarité entre les variables : la note et la recommandation étant par définition étroitement liées, le modèle ne fait en partie que confirmer cette relation structurelle. Des algorithmes plus complexes comme les forêts aléatoires ou le gradient boosting pourraient révéler des interactions subtiles entre les variables secondaires que l'arbre de décision simple ne capture pas.

8.3. Risques et mitigations

Le principal risque associé à ce projet est le biais de confirmation : interpréter les résultats à la lumière de ce que l'on s'attendait à trouver. Pour atténuer ce risque, chaque analyse a été accompagnée d'une interprétation alternative, et les cas où les

résultats infirment les hypothèses initiales notamment l'absence d'effet du type de peau sur la satisfaction ont été explicitement documentés et discutés

Un second risque concerne la représentativité du corpus. Les utilisatrices de Sephora constituent un profil de consommatrice spécifique urbaine, connectée, à pouvoir d'achat moyen à élevé qui ne reflète pas nécessairement l'ensemble des consommatrices du secteur dermocosmétique. Les résultats obtenus ne sont donc pas directement transférables à des segments de population différents, notamment les marchés émergents ou les circuits de distribution alternatifs

Conclusion

La reconnaissance de ces limites n'invalide pas les résultats obtenus, mais en précise le périmètre de validité et renforce la transparence scientifique de la démarche analytique adoptée. Ces limites constituent autant de pistes d'amélioration concrètes, qui seront développées dans la section 9 consacrée aux perspectives et prolongements analytiques envisageables

9 Perspectives et améliorations futures

Introduction

Un projet analytique n'est jamais définitif — il constitue une étape dans un processus d'apprentissage et d'amélioration continu. Cette section propose des pistes concrètes pour enrichir et prolonger les analyses réalisées, tant sur le plan des données que des méthodes et des outils mobilisés, en s'appuyant sur les limites identifiées en section 8

9.1 Améliorations possibles des données

Plusieurs enrichissements des données permettraient d'approfondir significativement les analyses :

Intégration de données démographiques : âge, localisation géographique, historique d'achat permettrait des segmentations consommateurs plus précises et des analyses de profil plus approfondies.

Accès à des données en temps réel via une API Sephora si elle était disponible publiquement permettrait de travailler sur un corpus actualisé et de détecter des tendances émergentes comme l'essor de la K-beauty ou du skincare minimaliste. Troisièmement, l'ajout de données issues d'autres plateformes comme Ulta Beauty, Amazon, pharmacies en ligne permettrait de comparer les comportements d'évaluation selon les canaux de distribution et d'évaluer la généralisabilité des résultats obtenus.

9.2 Prolongements analytiques

Sur le plan analytique, plusieurs axes d'approfondissement sont envisageables. Premièrement, des techniques NLP plus avancées modèles BERT, RoBERTa, analyse des entités nommées permettraient une analyse contextuelle plus fine des avis textuels, capable de détecter l'ironie, le sarcasme et les références spécifiques aux ingrédients cosmétiques, là où VADER montre ses limites.

Deuxièmement, une analyse de saisonnalité plus approfondie en croisant les catégories de produits avec les mois de publication des avis pourrait révéler des patterns d'achat saisonniers pertinents pour les stratégies marketing des marques.

Troisièmement, des algorithmes de machine learning plus complexes forêts aléatoires, gradient boosting pourraient révéler des interactions subtiles entre

variables secondaires que l'arbre de décision simple ne capture pas, comme discuté en section 8.2 .

9.3 L'intelligence artificielle comme levier d'analyse : apports et perspectives

Dans le cadre de ce projet, l'intelligence artificielle a été mobilisée à deux niveaux distincts :

VADER : un modèle de traitement automatique du langage naturel a été utilisé pour analyser le sentiment des avis textuels, révélant que 89,9% des avis expriment un contenu positif, un résultat significativement différent de celui obtenu par la simple catégorisation des notes.

Arbre de décision : un modèle qui a été appliqué pour identifier les variables les plus déterminantes dans le comportement de recommandation, confirmant que la note attribuée explique 99,97% de la capacité prédictive du modèle

Ces deux applications illustrent la valeur ajoutée des techniques d'intelligence artificielle dans l'analyse des comportements consommateurs, au-delà des approches purement descriptives. Dans de futures itérations, des modèles génératifs pourraient être utilisés pour synthétiser automatiquement les avis clients et identifier des tendances émergentes dans le discours consommateur. Par ailleurs, des systèmes de recommandation personnalisée basés sur le profil cutané et l'historique d'évaluation pourraient constituer un prolongement applicatif direct des résultats obtenus dans ce projet

Conclusion

Les perspectives identifiées dans cette section confirment que ce projet constitue une première étape solide dans une démarche analytique qui pourrait être considérablement enrichie. Trois axes prioritaires se dégagent pour une version améliorée de ce travail : l'enrichissement et la diversification des sources de données, le recours à des techniques NLP avancées pour une analyse textuelle plus fine, et l'intégration de modèles prédictifs plus complexes. Le calendrier d'exécution présenté dans la section 10 retrace les grandes étapes qui ont structuré la réalisation de ce projet.

10. Calendrier d'exécution des tâches

Période	Phase / Activité	Livrables / Résultats attendus
20 - 30 janvier	Choix du sujet et cadrage du projet	Sujet validé, compréhension des attentes, plan initial du travail
30 janvier - 8 février	Élaboration du plan de travail et recherche préliminaire	Plan de travail structuré et déposé
9 - 20 février	Recherche documentaire et compréhension du contexte métier	Synthèse des références, section contexte et revue descriptive
21 février - 5 mars	Acquisition et compréhension des données	Description des données, dictionnaire de données, évaluation de la qualité
6 - 12 mars	Analyse exploratoire des données (EDA)	Résultats exploratoires, graphiques initiaux, rapport de progrès
13 - 31 mars	Analyses descriptives et interprétation métier	Analyses par catégories, périodes, indicateurs clés
1 - 10 avril	Visualisation des données et création du tableau de bord	Dashboards et visualisations (Power BI / Excel)
11 - 18 avril	Rédaction finale du rapport	Rapport final rédigé et structuré
19 - 22 avril	Préparation de la vidéo de démonstration	Vidéo de démonstration finalisée
23 avril	Dépôt final	Dépôt du rapport final et de la vidéo

Conclusion générale

Ce projet de synthèse a constitué une expérience analytique complète, mobilisant l'ensemble des compétences acquises au cours du baccalauréat en informatique et les mettant au service d'une problématique concrète et actuelle dans le secteur dermocosmétique. Il a permis de mettre en œuvre une démarche structurée et rigoureuse de l'acquisition des données jusqu'à la visualisation interactive sous Power BI en passant par toutes les étapes clés de l'analyse de données : prétraitement, exploration, analyses avancées et interprétation métier.

À travers l'analyse de deux jeux de données distincts et complémentaires issus de la plateforme Sephora représentant plus d'un million d'avis clients et près de neuf mille produits, ce travail a permis de répondre à la question centrale posée en introduction « comment la marque, le prix, la catégorie et le profil utilisateur influencent-ils les évaluations et comportements clients dans le secteur dermocosmétique ? »

Les résultats obtenus apportent des réponses nuancées et analytiquement rigoureuses. Contrairement aux hypothèses initiales, le prix d'un produit ne constitue pas un facteur déterminant de la satisfaction client, les consommateurs ajustent leurs attentes en fonction du positionnement tarifaire, neutralisant ainsi l'avantage potentiel des produits haut de gamme, comme l'illustre le coefficient de corrélation de Pearson de 0,019 entre prix et note. De même, la popularité d'une marque mesurée par le volume d'avis ne garantit pas une meilleure évaluation : les marques spécialisées, ciblant une clientèle informée aux attentes alignées avec l'offre, obtiennent systématiquement de meilleures notes que les grandes marques généralistes. Le profil cutané, quant à lui, exerce une influence négligeable sur la satisfaction, les écarts entre types de peau étant inférieurs à 0,04 point suggérant que les produits référencés sur la plateforme répondent de manière relativement homogène aux besoins des différents profils cutanés.

L'analyse de sentiment réalisée grâce à l'outil VADER a révélé que 89,9% des avis expriment un contenu textuel positif un résultat significativement différent de celui obtenu par la simple catégorisation des notes (64% de notes à 5 étoiles) illustrant la valeur ajoutée des techniques de traitement automatique du langage naturel dans l'analyse des comportements consommateurs. La modélisation prédictive par arbre de décision a quant à elle confirmé que la note attribuée constitue le seul prédicteur

significatif du comportement de recommandation, expliquant 99,97% de la capacité prédictive du modèle, loin devant le prix, la marque et le profil cutané.

Ce projet illustre la complémentarité entre l'expertise métier et les compétences analytiques. La double formation en cosmétologie et en informatique a permis d'apporter une profondeur d'interprétation que les données seules ne peuvent offrir exemple : comprendre pourquoi une peau sèche réagit différemment à certaines formulations, pourquoi une marque dermocosmétique professionnelle comme Dermalogica génère une satisfaction plus homogène pour tous les types de peau, ou encore pourquoi le terme dry apparaît dans les avis positifs comme dans les avis négatifs selon le contexte d'utilisation. Cette capacité à lire les données à travers le prisme de l'expertise terrain constitue une valeur ajoutée distinctive dans le domaine de l'analyse de données appliquée, et reflète l'ambition d'une démarche à la fois rigoureuse sur le plan informatique et pertinente sur le plan métier.

Au-delà des résultats spécifiques obtenus, ce projet a démontré la richesse analytique des données générées par les plateformes de commerce en ligne et leur potentiel pour éclairer les décisions stratégiques des acteurs du secteur dermocosmétique qu'il s'agisse de marques souhaitant optimiser leur positionnement, de distributeurs cherchant à mieux comprendre leurs consommateurs, ou de professionnels de la beauté désireux d'affiner leurs recommandations. Il confirme également que l'analyse de données, lorsqu'elle est conduite avec rigueur et mise en perspective par une expertise métier solide, constitue un levier décisionnel puissant et accessible, y compris dans des secteurs aussi complexes et humains que celui de la dermocosmétique.

11. Bibliographie

- [1] S. Dhummad, «The imperative of exploratory data analysis in machine learning,» *Scholars Journal of Engineering and Technology*, vol. 13, n° %101, pp. 30-44, 2025.
- [2] Majeed, A. et Lee, S., «Anonymization techniques for privacy preserving data publishing: A comprehensive survey,» *IEEE Access*, vol. 9, p. 8512–8545, 2020.
- [3] Thakur, M. et Bala, R., «Défis et opportunités des réglementations cosmétiques : une perspective globale,» *International Journal of Toxicology*, 2025.
- [4] Park, Y. W. et Hong, P., «Beauty Reimagined : naviguer dans la transformation numérique de l'industrie cosmétique,» chez *Cosmetics marketing strategy in the era of digital ecosystem*, Springer Nature Singapore, 2024, pp. 47-74.
- [5] Roy, K., Paul, U. K. et Dawn, S., «A duo-decade of research on electronic word of mouth,» *Journal of Information & Knowledge Management*, vol. 24, n° %104, 2025.
- [6] J. D. Velásquez, «An analysis of trends, challenges, and opportunities in retail analytics,» *International Journal of Market Research*, vol. 67, n° %14, pp. 394-422, 2025.
- [7] Filieri, R. et McLeay, F., «E-WOM and accommodation: An analysis of the factors that influence travelers' adoption of information from online reviews,» *Journal of Travel Research*, vol. 53, pp. 44-57, 2014.
- [8] Wei, Z. H., Bi, J. W. et Han, T. Y., «The Impact of Temporal Distance on Online Ratings,» *Journal of Hospitality & Tourism Research*, 2025.
- [9] Meng, Y., Park, S. et Um, G., «How review sentiment influences ratings in Generative AI applications,» *Journal of Retailing and Consumer Services*, vol. 88, 2026.
- [10] Camilleri, M. A. et Filieri, R., «Customer satisfaction and loyalty with online consumer reviews: Factors affecting revisit intentions,» *International Journal of Hospitality Management*, vol. 103575, p. 114, 2023.

